Data schema: `data/processed/reviews_clean.parquet`

Output of the preprocessing step (owner: P1). **393.578 dòng × 20 cột.** Mỗi dòng là một review đã loại trùng. Tái tạo: `python scripts/run_ingestion.py` rồi `python scripts/run_preprocessing.py`.

```python
import pandas as pd
df = pd.read_parquet("data/processed/reviews_clean.parquet")
```

Quy tắc chung

- `review_id` là khoá duy nhất. Dùng nó làm ID khi lưu vào vector DB hoặc ghép bảng.
- **Hai cột văn bản, hai mục đích. Không ghi đè cột này bằng cột kia.**
  - `review_text`: văn bản tự nhiên (giữ chữ hoa, dấu câu, từ phủ định). Dùng cho **embedding, RAG, LLM, sentiment**.
  - `text_normalized`: chữ thường, đã bỏ stopword (giữ `not`, `no`, `never`...). Dùng cho **TF-IDF, từ khoá, topic modeling, clustering**.
- 2 dòng có `text_normalized` rỗng (review chỉ gồm stopword). Hãy dùng `fillna("")`/bỏ qua khi vector hoá.

Các cột

Cột	Kiểu	Mô tả	Dùng bởi
`review_id`	int64	ID duy nhất của review	tất cả
`product_id`	string	Mã sản phẩm (không có tên/mô tả sản phẩm trong dataset)	P3, P4, P5
`user_id`	string	Mã người dùng	P2
`profile_name`	string	Tên hiển thị (có thể null, chứa thông tin cá nhân, **không đưa vào báo cáo**)	-
`score`	int8	Số sao 1-5	P2, P3
`sentiment`	category	`negative` (1-2 sao), `neutral` (3), `positive` (4-5), **suy ra từ sao**, không phải từ văn bản	P2 (so sánh với sentiment từ văn bản)
`is_negative`	bool	`score <= 2`. Tập review dùng để phân tích vấn đề	P3
`summary`	string	Tiêu đề review đã làm sạch (có thể null)	-
`text`	string	Nội dung review đã làm sạch (bỏ HTML, URL, ký tự lặp)	-
`review_text`	string	`summary + ". " + text`	**P2, P4, P5**
`text_normalized`	string	Bản chuẩn hoá nặng của `review_text`	**P3** (TF-IDF, topic, clustering)
`char_count`, `word_count`	int32	Độ dài của `text`	P4 (chunking)
`review_date`	datetime	Ngày review	P2 (xu hướng)
`review_year`, `review_month`	int16/int8	Tách từ `review_date`	P2
`timestamp`	int64	Unix timestamp gốc	-

Cột	Kiểu	Mô tả	Dùng bởi
`helpful_yes`, `helpful_total`	int32	Số vote hữu ích / tổng vote	P3 (xếp hạng)
`helpful_ratio`	float32	`helpful_yes / helpful_total`. **NaN ở ~47% dòng** (chưa ai vote)	P3

Lưu ý khi dùng

- **Vector DB (P4):** Chroma và các DB tương tự không nhận `NaN` / `datetime` trong metadata. Chuyển `helpful_ratio` NaN thành `None`/bỏ khoá, và `review_date` thành chuỗi hoặc số trước khi nạp.
- **Review dài (P4):** 16,6% review dài hơn 128 từ và 6,2% dài hơn 200 từ. Model embedding nhỏ sẽ cắt phần dư, hãy chia đoạn (chunk) hoặc kiểm tra giới hạn token của model.
- **Dữ liệu lệch:** 78% positive và 14,5% negative. Khi đánh giá clustering/sentiment, báo cáo cả chỉ số theo từng lớp, không chỉ accuracy tổng.
- **Không có tài liệu sản phẩm/chính sách** trong dataset. Hai kho tri thức của RAG cần được tạo thêm (xem kế hoạch của P4).